

Table des matières

1	Introduction	3
1.1	Contexte	3
1.2	Objectif du projet	3
1.3	Méthodologie	3
2	Première approche : BCS-SPL	4
2.1	Description	4
2.2	Résultats	4
3	Seconde approche : BCS-DL	7
3.1	Description	7
3.2	Résultats	8
4	Ouverture	8

1 Introduction

1.1 Contexte

L'utilisation des images satellites et des prises de vue in-situ est essentielle pour l'analyse des environnements polaires. Cependant, l'accumulation massive de ces images, acquises à haute fréquence temporelle, entraîne des défis en termes de stockage et de traitement. Par ailleurs, ces images peuvent être affectées par divers types de bruits, tels que la buée, le givre, ou encore des perturbations causées par le mouvement des caméras.

Dans ce contexte, la réduction de la taille des données tout en préservant l'information utile est un enjeu majeur. L'objectif est de mettre en place une méthodologie permettant d'échantillonner efficacement les images afin de faciliter leur stockage et leur analyse tout en garantissant une reconstruction fidèle.

1.2 Objectif du projet

Le but de ce projet est de développer un modèle de reconstruction d'images basé sur les principes du *Blocked Compressive Sensing* (BCS) en combinant deux approches :

1. **Une approche classique (BCS-SPL)**, utilisant l'algorithme *Smoothed Projected Landweber* (SPL) pour reconstruire les images compressées.
2. **Une approche basée sur l'apprentissage profond (BCS-DL)**, exploitant un réseau de neurones pour améliorer la qualité de la reconstruction.

Ces deux méthodes seront comparées afin d'évaluer leurs performances respectives en termes de fidélité de reconstruction et de robustesse au bruit.

1.3 Méthodologie

Notre approche consiste à diviser les images en blocs de taille $B \times B$, puis à les projeter dans un espace de dimension réduite à l'aide d'une matrice de mesure aléatoire Φ . L'image originale est ensuite reconstruite soit par la méthode SPL, soit par un réseau de neurones entraîné spécifiquement pour cette tâche.

Les étapes principales du projet sont les suivantes :

- Extraction des blocs $B \times B$ à partir des images sources.
- Génération des mesures compressées $y = \Phi x$.
- Reconstruction des images via l'algorithme SPL et via un réseau de neurones profond.
- Comparaison des performances des deux méthodes à l'aide d'indicateurs tels que le PSNR (Peak Signal-to-Noise Ratio).

2 Première approche : BCS-SPL

2.1 Description

La reconstruction d'images compressées à partir de mesures aléatoires repose sur différentes techniques d'optimisation. Une des approches classiques du *Blocked Compressive Sensing* (BCS) est l'algorithme **Smoothed Projected Landweber** (SPL), qui s'appuie sur une itération progressive pour estimer l'image originale à partir de ses mesures partiellement observées.

L'algorithme SPL se base sur le principe de **descente de gradient projetée**, où l'image reconstruite est ajustée itérativement afin de minimiser l'erreur entre les mesures obtenues et les mesures reconstruites. Pour garantir une meilleure convergence et éviter les artefacts, des contraintes de parcimonie sont appliquées via un seuillage dans un domaine transformé (notamment la transformée en cosinus discrète, DCT). Cette approche présente plusieurs avantages :

- Elle ne nécessite pas d'apprentissage préalable et peut être appliquée directement sur n'importe quelle image.
- Elle permet d'obtenir une reconstruction stable et robuste aux variations des données.
- Elle est théoriquement bien fondée et repose sur des principes mathématiques clairs.

Cependant, la méthode SPL présente également certaines limites :

- Le processus itératif peut être long et nécessiter plusieurs ajustements pour optimiser la convergence.
- La qualité de la reconstruction dépend fortement du choix du paramètre de seuillage et du nombre d'itérations.
- Pour des taux de compression élevés, les artefacts visuels peuvent être plus prononcés.

Dans cette section, nous détaillons :

- Le principe mathématique de la reconstruction SPL.
- Les choix des hyperparamètres et des critères d'arrêt.
- Les performances obtenues en fonction du ratio de compression.

2.2 Résultats

Dans cette première approche, nous étudions l'influence de la taille de patch sur la qualité de la reconstruction (mesurée ici par le *Peak Signal-to-Noise Ratio* ou PSNR) et sur le temps d'exécution. Les tests ont été effectués avec des tailles de patch allant de 10 à 150.

D'après les Figures 1 et 5, on constate que :

- **PSNR et taux d'erreur** :
 - À mesure que la taille de patch augmente, le PSNR a tendance à s'élever, reflétant une meilleure précision de reconstruction.
 - Inversement, le taux d'erreur diminue, ce qui confirme l'amélioration de la qualité.
- **Temps d'exécution** : le temps de calcul croît de façon significative avec la taille de patch, en particulier pour les valeurs les plus élevées.

Lorsque le **ratio** augmente, le PSNR s'améliore (et donc l'erreur diminue) mais, de façon concomitante, le temps d'exécution peut aussi augmenter, notamment pour de grandes tailles de patch. Il existe donc un compromis entre la précision visée et le coût computationnel.

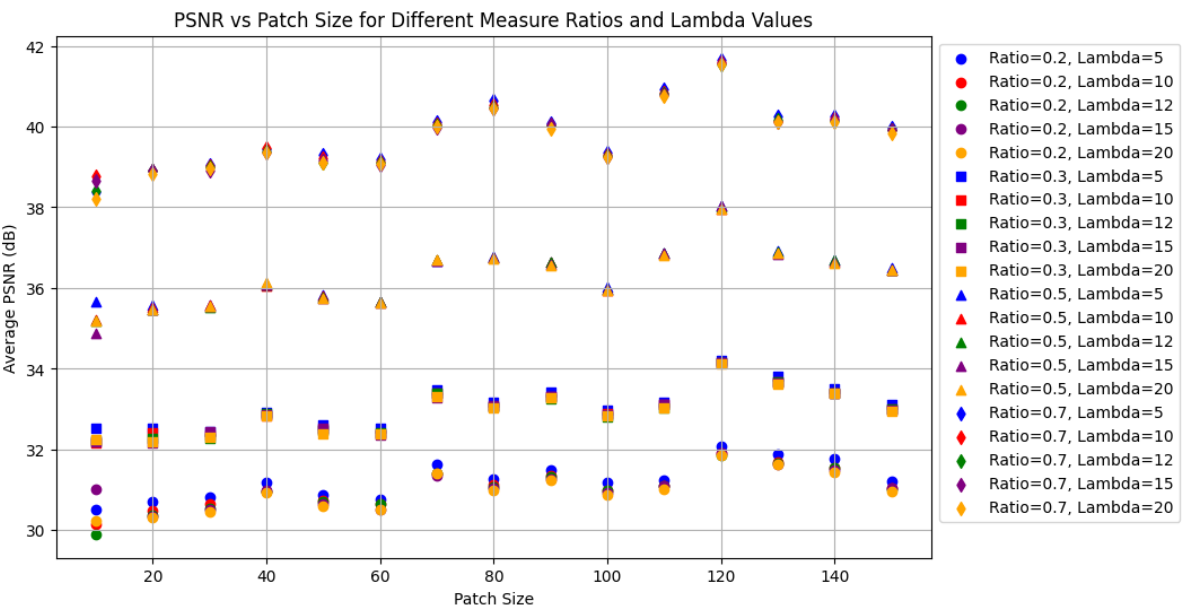


FIGURE 1 – Évolution du PSNR en fonction de la taille de patch.

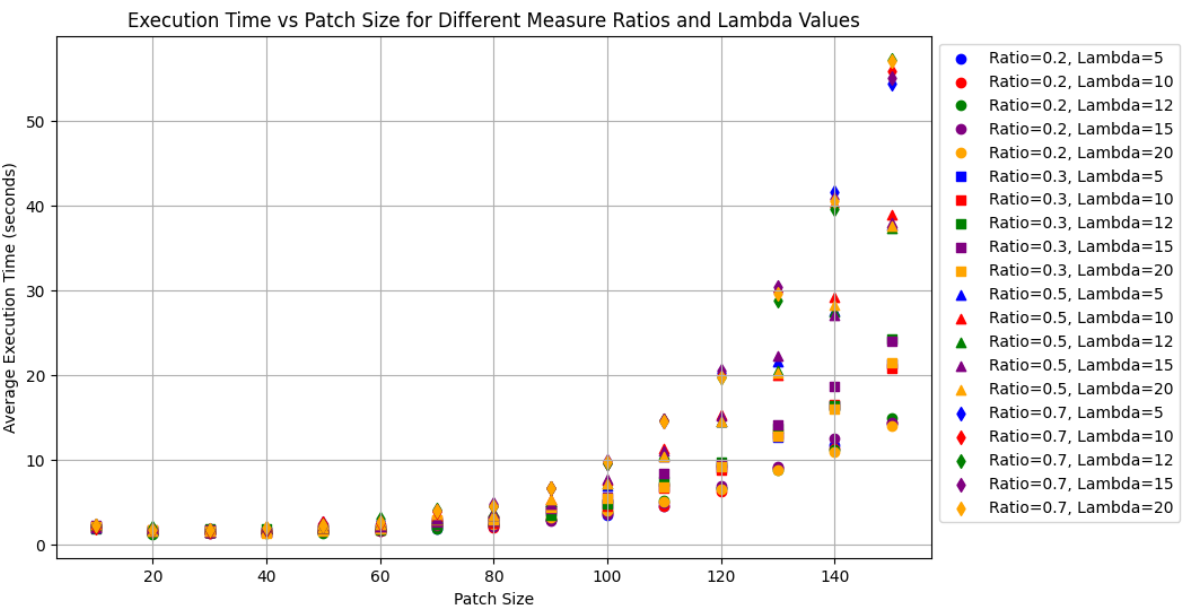


FIGURE 2 – Évolution du temps d'exécution en fonction de la taille de patch.

Analyse spécifique pour des patches de taille de 10 à 50 :

- **Erreur moyenne et PSNR** : ils demeurent approximativement constants sur cet intervalle.
- **Tendance en forme de « U » pour le temps d'exécution** : le temps d'exécution moyen atteint son minimum pour une taille de patch de 30, ce qui constitue le meilleur compromis parmi ces petites tailles de patch.

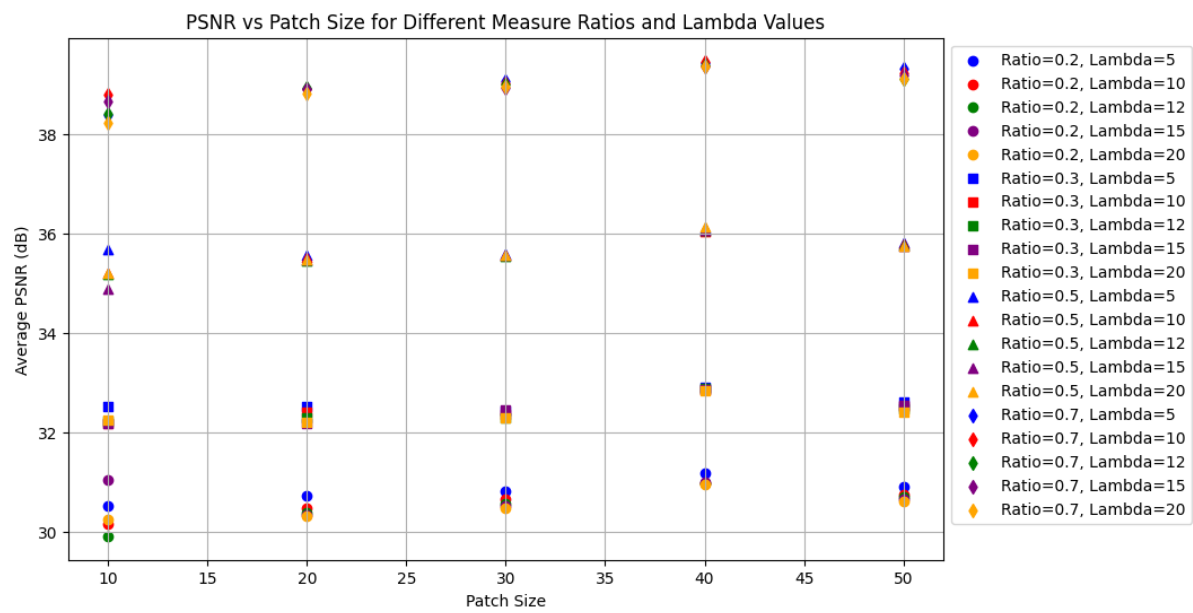


FIGURE 3 – Évolution du PSNR pour des tailles de patch de 10 à 50.




FIGURE 4 – Évolution du temps d'exécution pour des tailles de patch de 10 à 50.

3 Seconde approche : BCS-DL

3.1 Description

L'approche classique du *Blocked Compressive Sensing* (BCS) repose sur des méthodes d'optimisation numérique pour reconstruire une image à partir d'un sous-échantillonnage. Cependant, ces techniques, bien que théoriquement solides, souffrent de certaines limitations :

- Elles nécessitent de résoudre un problème d'optimisation itératif, ce qui peut être long en temps de calcul.
- La reconstruction obtenue peut présenter des artefacts, notamment pour des taux de compression élevés.
- Elles ne capturent pas toujours efficacement les structures complexes des images naturelles.

Pour pallier ces limitations, nous explorons une seconde approche reposant sur l'apprentissage profond : **BCS-DL (Blocked Compressive Sensing avec Deep Learning)**. L'idée principale est d'utiliser un réseau de neurones pour apprendre à reconstruire une image directement à partir de ses mesures compressées.

Contrairement à la méthode SPL qui repose sur des modèles mathématiques explicites, l'approche BCS-DL exploite la puissance des réseaux neuronaux pour modéliser implicitement les relations complexes entre les pixels d'une image. Après un entraînement sur un ensemble d'images compressées, le réseau est capable de généraliser et de reconstruire efficacement de nouvelles images compressées avec un temps d'inférence réduit.

Dans cette section, nous détaillons :

- **La structure du réseau de neurones utilisé** : notre modèle est constitué d'une succession de couches **Dense**, permettant d'apprendre la reconstruction des images à partir des mesures compressées.
- **Le choix des hyperparamètres et de la fonction de coût** : conformément aux recommandations du cours, nous avons conservé le nombre de couches initialement proposé et utilisé les mêmes fonctions d'activation pour garantir une stabilité de l'apprentissage.
- **Le processus d'entraînement et d'évaluation du modèle** : nous avons entraîné le modèle sur un ensemble d'images du glacier et évalué sa capacité de reconstruction en mesurant des métriques telles que le PSNR.
- **Une comparaison des performances obtenues avec la méthode SPL** : nous analysons les différences entre BCS-DL et BCS-SPL en termes de fidélité de reconstruction et de rapidité d'exécution.

3.2 Résultats

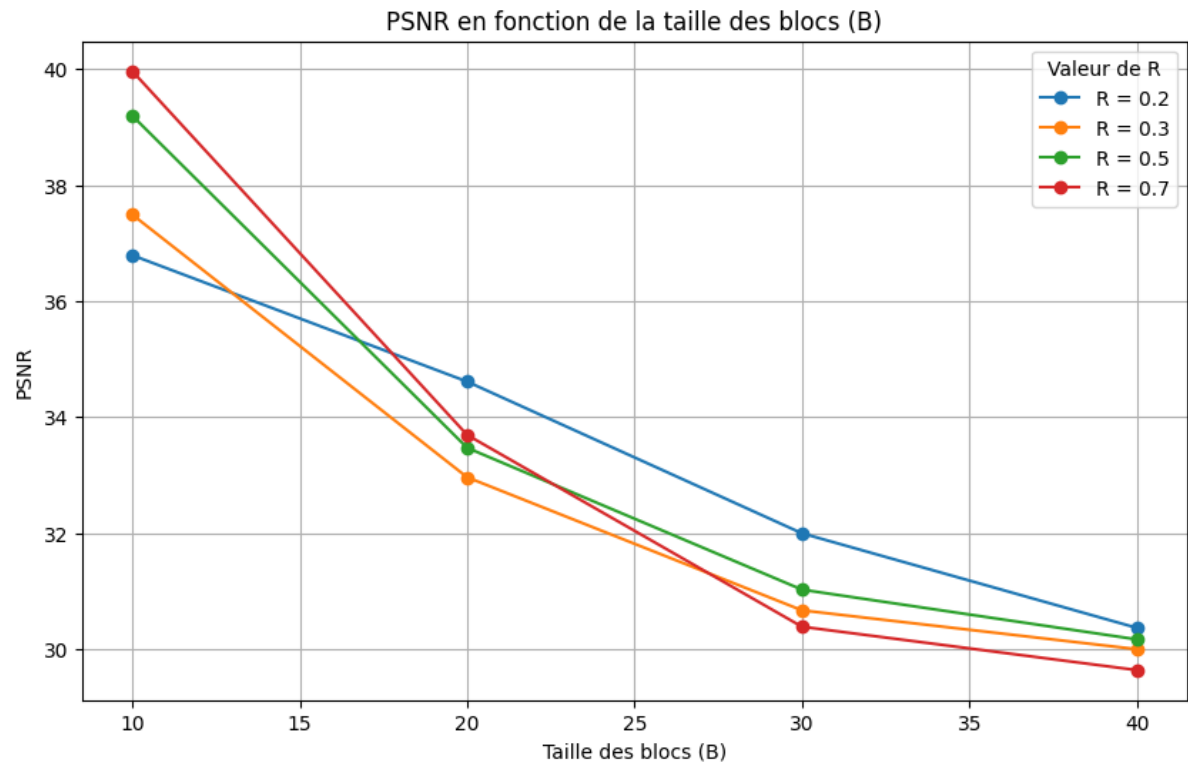


FIGURE 5 – Évolution du temps d'exécution en fonction de la taille de patch.

Les résultats obtenus montrent une **diminution du PSNR avec l'augmentation de la taille des blocs**. En particulier, la meilleure reconstruction est observée pour une taille de patch de 10×10 avec **70% d'échantillonnage**, atteignant un **PSNR de 40 dB**. Toutefois, au-delà de cette configuration, le modèle actuel semble atteindre ses limites et **ne parvient pas à améliorer significativement la qualité de reconstruction**.

Enfin, un **avantage notable** de cette approche est son **faible temps d'inférence**, permettant une reconstruction rapide des images compressées. Une analyse plus approfondie des temps de calcul pourrait être réalisée afin de confirmer cet aspect et comparer la méthode avec d'autres solutions plus complexes.

4 Ouverture

Une piste d'amélioration pourrait être l'utilisation de **réseaux de neurones convolutifs (CNN)** ou d'**architectures avancées comme U-Net**, mieux adaptées à la capture des structures locales et des relations spatiales dans l'image.